

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное учреждение высшего образования

**«Национальный исследовательский Нижегородский государственный университет им. Н.И. Лобачевского»
(ННГУ)**

Институт информационных технологий, математики и механики

Кафедра: Математического обеспечения и суперкомпьютерных технологий

Направление подготовки: «Фундаментальная информатика и информационные технологии»

Профиль подготовки: «Инженерия программного обеспечения»

Аналитический обзор

по научно-исследовательской работе

на тему:

**«Алгоритмы восстановления полигональной и твердотельной геометрии
из воксельных биомедицинских данных»**

Выполнил:

студент группы 3823Б1ФИ1

_____ Дорофеев И. Д.

Научный руководитель:

Доцент кафедры ПМ, к.ф.-м.н.,

_____ Кириллин М. Ю.

Нижний Новгород

2026 г.

1 ВВЕДЕНИЕ

Восстановление геометрии из воксельных данных — переход от регулярной трёхмерной решётки скалярных или размеченных значений (результат МРТ, КТ, микроскопии, криосекции) к явному геометрическому представлению — является одним из базовых этапов вычислительной биомедицины. Полученная геометрия используется в визуализации, планировании операций, биомеханическом конечно-элементном анализе и моделировании переноса излучения. В отличие от данных общего назначения, биологические объёмы обладают рядом специфических черт: многотканевостью (десятки вложенных областей), наличием тонких структур толщиной в один-два вокселя, извилистых поверхностей (кора мозга) и топологически сложных каналов (форамини, сосуды).

Настоящий обзор систематизирует алгоритмы восстановления геометрии из вокселей, охватывая как **поверхностные** (полигональные оболочки), так и **твёрдотельные** (объёмные тетраэдральные) методы. Отдельное внимание уделено проблеме ступенчатых артефактов и современным обучаемым представлениям, получившим бурное развитие в последние пять лет.

Классификация рассматриваемых семейств методов приведена в Таблице 1.

Таблица 1 – Семейства методов восстановления геометрии из вокселей

Группа	Выход	Представители
Извлечение изоповерхностей	поверхность	Marching Cubes, SurfaceNets, Dual Contouring, Flying Edges
Неявные / обучаемые	поверхность	Poisson, DeepSDF, Occupancy Nets, Neural MC/DC
Твёрдотельные (объёмные)	тет-сетка	TetGen, fTetWild, CGAL Mesh_3, DMTet

2 ИЗВЛЕЧЕНИЕ ПОВЕРХНОСТЕЙ ИЗ ВОКСЕЛЬНОГО ПОЛЯ

Исторически первым и наиболее распространённым семейством являются алгоритмы прямого извлечения изоповерхностей. Классический Marching Cubes (MC) [1] обходит логические кубы решётки и по 8-битному индексу знаков в вершинах выбирает локальную триангуляцию из предвычисленной таблицы. При всей эффективности MC страдает от топологических неоднозначностей на гранях и, что критично для сегментированных бинарных масок, от выраженной **ступенчатости** (terracing) — поверхность распадается на осевые площадки. Современная реализация Flying Edges [4] устраняет неоднозначности однопроходным сканированием рёбер и обеспечивает масштабируемость на больших объёмах.

Для борьбы со ступенчатостью на бинарных медицинских данных предложены методы, работающие не с изоуровнем, а с положением вершин. Constrained Elastic SurfaceNets [2] размещает по одному узлу в каждом граничном кубе и релаксирует их положения под ограничением, оставаясь в пределах вокселя; это даёт гладкие поверхности без потери объёма и без осевого алиасинга. Dual Contouring [3] обобщает идею, используя эрмитовы данные (нормали) для восстановления острых рёбер: вершины ставятся внутри кубов путём минимизации квадратичной ошибки к касательным плоскостям. Эти дуальные подходы принципиально лучше приспособлены к резким сменам формы между соседними срезами, порождающим ступеньки в MC.

Отдельную ветвь образуют методы реконструкции по облакам точек или градиентным полям: Screened Poisson Surface Reconstruction [5] решает уравнение Пуассона относительно индикаторной функции, что даёт водонепроницаемую гладкую поверхность и хорошо работает при зашумлённых границах.

3 НЕЯВНЫЕ И ОБУЧАЕМЫЕ ПРЕДСТАВЛЕНИЯ

За последние годы центр тяжести сместился к **неявным** представлениям, в которых форма задаётся функцией $f(\mathbf{x})$ (знаковое расстояние или занятость), а поверхность извлекается как её нулевой уровень. DeepSDF [6]

обучает нейросеть регрессии знакового расстояния, а *Occupancy Networks* [7] — вероятности принадлежности точки телу; обе модели дают непрерывное разрешение-независимое представление, что особенно ценно при анизотропных или низкоразрешённых томографических данных.

Финальный переход от неявного поля к сетке долгое время оставался узким местом: применение классического МС к обученному полю вносит собственные артефакты. Появились **обучаемые** извлекатели: *Neural Marching Cubes* [8] и *Neural Dual Contouring* [9] предсказывают положения вершин и локальную топологию непосредственно из поля, восстанавливая тонкие детали и острые рёбра лучше фиксированных таблиц. Метод *Reach for the Arcs* [11] реконструирует поверхность из знакового поля, используя дуговые оценки расстояний, и точнее передаёт мелкие структуры.

В биомедицине неявные представления применяются как напрямую, так и в связке с сегментацией. Обзор [12] систематизирует сквозные подходы «изображение → сетка» для медицинских данных, а более общий обзор обучаемых методов реконструкции сеток дан в [17]. Среди прикладных работ: *MISNeR* [13] — неявное представление формы для визуализации объёмов; реконструкция поверхностей из свободноручного 3D-УЗИ с геометрическими ограничениями [14]; восстановление сеток нейронов из стеков микроскопии неявными представлениями [15]; шаблонно-управляемая реконструкция сегментов лёгких неявными функциями [16]. Общей чертой является способность работать с неполными, анизотропными и зашумлёнными данными, типичными для клинических модальностей.

Из русскоязычных работ отметим [20], где предложена модификация алгоритма *Marching Cubes* для построения трёхмерного представления по изображениям с усреднением точек пересечения, снижающим ступенчатость.

4 ТВЕРДОТЕЛЬНЫЕ (ОБЪЁМНЫЕ) МЕТОДЫ

Для биомеханического и оптического моделирования требуется не только поверхность, но и **объёмная** конформная сетка. Классический генератор *TetGen* [19] строит качественную тетраэдризацию Делоне по заданной граничной поверхности с ограничениями на радиус-рёберное отношение. Пакет *CGAL Mesh_3* формирует объёмную сетку прямо из размеченного изображения или неявной функции, контролируя размеры граней, отклонение от границы и размеры ячеек; он естественно поддерживает многотканевые (*multi-domain*) области с общими границами — ключевое свойство для вложенных биологических структур.

Существенным прорывом стал *fTetWild* [18] — «быстрая тетраэдризация в диких условиях», устойчивая к самопересечениям и дефектам входной поверхности за счёт приближённого удовлетворения ограничений и гибридного целочисленно-рационального ядра. Для дефектных сегментаций, характерных для медицинских данных, такая устойчивость критична.

Отдельного упоминания заслуживает *Deep Marching Tetrahedra (DMTet)* [10] — гибридное представление, деформирующее фоновую тетраэдральную решётку и предсказывающее знаковое поле в её узлах, что позволяет синтезировать поверхности высокого разрешения и напрямую получать объёмную дискретизацию в обучаемом конвейере.

5 СПЕЦИФИКА БИОМЕДИЦИНСКИХ ДАННЫХ И ВЫВОДЫ

Применение перечисленных методов к биологическим объёмам осложняется рядом факторов. Многотканевость требует согласованных границ между соседними областями: независимое извлечение поверхностей порождает зазоры и пересечения, поэтому предпочтительны *multi-domain*-генераторы (*CGAL Mesh_3*) либо построение вложенных оболочек. Тонкие структуры (мембраны, сосуды) на решётке толщиной в один воксель распадаются при МС, что делает дуальные и неявные методы предпочтительными. Ступенчатость, порождаемая осевой природой сканирования, устраняется либо на этапе извлечения (*SurfaceNets*, *Dual Contouring*), либо постобработкой (см. обзор методов улучшения сеток).

Наблюдаемая тенденция последних пяти лет — вытеснение фиксированных табличных извлекателей

обучаемыми неявными представлениями, особенно в задачах с неполными и анизотропными данными. При этом классические (MC, Flying Edges) и объёмные (TetGen, fTetWild, CGAL) методы сохраняют значение как надёжные детерминированные инструменты, дающие контролируемые топологические гарантии, необходимые для физического моделирования. Оптимальным для многотканевых биомедицинских задач представляется гибридный конвейер: детерминированное построение согласованных оболочек с последующим объёмным доуплотнением, дополняемое обучаемыми методами там, где данные разрежены или зашумлены.

СПИСОК ЛИТЕРАТУРЫ

- [1] Lorensen W. E., Cline H. E. Marching cubes: A high resolution 3D surface construction algorithm // ACM SIGGRAPH Computer Graphics. — 1987. — Vol. 21, no. 4. — P. 163–169.
- [2] Gibson S. F. F. Constrained elastic SurfaceNets: Generating smooth surfaces from binary segmented data // Proc. MICCAI. — Springer, 1998. — P. 888–898.
- [3] Ju T., Losasso F., Schaefer S., Warren J. Dual contouring of Hermite data // ACM Transactions on Graphics (SIGGRAPH). — 2002. — Vol. 21, no. 3. — P. 339–346.
- [4] Schroeder W., Maynard R., Geveci B. Flying edges: A high-performance scalable isocontouring algorithm // Proc. IEEE Symp. on Large Data Analysis and Visualization (LDAV). — IEEE, 2015. — P. 33–40.
- [5] Kazhdan M., Hoppe H. Screened Poisson surface reconstruction // ACM Transactions on Graphics. — 2013. — Vol. 32, no. 3. — Art. 29.
- [6] Park J. J., Florence P., Straub J., Newcombe R., Lovegrove S. DeepSDF: Learning continuous signed distance functions for shape representation // Proc. IEEE/CVF CVPR. — 2019. — P. 165–174.
- [7] Mescheder L., Oechsle M., Niemeyer M., Nowozin S., Geiger A. Occupancy networks: Learning 3D reconstruction in function space // Proc. IEEE/CVF CVPR. — 2019. — P. 4460–4470.
- [8] Chen Z., Zhang H. Neural marching cubes // ACM Transactions on Graphics (SIGGRAPH Asia). — 2021. — Vol. 40, no. 6. — Art. 251.
- [9] Chen Z., Tagliasacchi A., Funkhouser T., Zhang H. Neural dual contouring // ACM Transactions on Graphics (SIGGRAPH). — 2022. — Vol. 41, no. 4. — Art. 104.
- [10] Shen T., Gao J., Yin K., Liu M.-Y., Fidler S. Deep marching tetrahedra: a hybrid representation for high-resolution 3D shape synthesis // Advances in Neural Information Processing Systems (NeurIPS). — 2021. — Vol. 34.
- [11] Sellán S., Aigerman N., Jacobson A. Reach for the arcs: Reconstructing surfaces from SDFs via tangent points // Proc. ACM SIGGRAPH. — 2024. — Art. 27.
- [12] From pixels to polygons: A survey of deep learning approaches for medical image-to-mesh reconstruction // Medical Image Analysis. — Elsevier, 2026. (arXiv:2505.03599).
- [13] Jin Y. et al. MISNeR: Medical implicit shape neural representation for image volume visualisation // Computer Graphics Forum. — 2024. — Vol. 43, no. 7. — Art. e15222.
- [14] Neural implicit surface reconstruction of freehand 3D ultrasound volume with geometric constraints // arXiv preprint arXiv:2401.05915. — 2024.
- [15] Neuronal mesh reconstruction from image stacks using implicit neural representations // Mathematics. — MDPI, 2025. — Vol. 13, no. 8. — Art. 1276.

- [16] Template-guided reconstruction of pulmonary segments with neural implicit functions // arXiv preprint arXiv:2505.08919. — 2025.
- [17] A review of deep learning-powered mesh reconstruction methods // arXiv preprint arXiv:2303.02879. — 2023.
- [18] Hu Y., Schneider T., Wang B., Zorin D., Panozzo D. Fast tetrahedral meshing in the wild // ACM Transactions on Graphics (SIGGRAPH). — 2020. — Vol. 39, no. 4. — Art. 117.
- [19] Si H. TetGen, a Delaunay-based quality tetrahedral mesh generator // ACM Transactions on Mathematical Software. — 2015. — Vol. 41, no. 2. — Art. 11.
- [20] Хернандес Фарсас Д. И., Гусман Кабрера Р., Кордова Фрага Т., Уамани Луна Х. З., Гомез Агилар Х. Ф. Модификация алгоритма Marching Cubes для получения трёхмерного представления плоского изображения // Труды Института системного программирования РАН. — 2020. — Т. 32, вып. 5. — С. 167–180.